

# **Inteligência Artificial**

## **Redes Neurais Artificiais ( Parte I )**

**Paulo Moura Oliveira**

*Departamento de Engenharias*

*Gabinete F2.15, ECT-1*

**UTAD**

*email: [oliveira@utad.pt](mailto:oliveira@utad.pt)*

## Porquê Utilizar Redes Neurais Artificiais?

- ✓ Atualmente as redes neuronais artificiais são um dos paradigmas da Inteligência Artificial e dos Sistemas Inteligentes.

### Algumas (potenciais) vantagens das redes neuronais:

1. Não necessitam de ser programadas, pois **podem aprender a partir de exemplos**.
2. A sua utilização pode-se **generalizar para dados que não foram utilizados no seu treino**.
3. São tolerantes a falhas: podem reproduzir saídas corretas a partir de **dados com ruído ou incompletos**.
4. São **rápidas**: as suas unidades de processamento trabalham em paralelo.
5. São relativamente “simples” de construir e treinar.

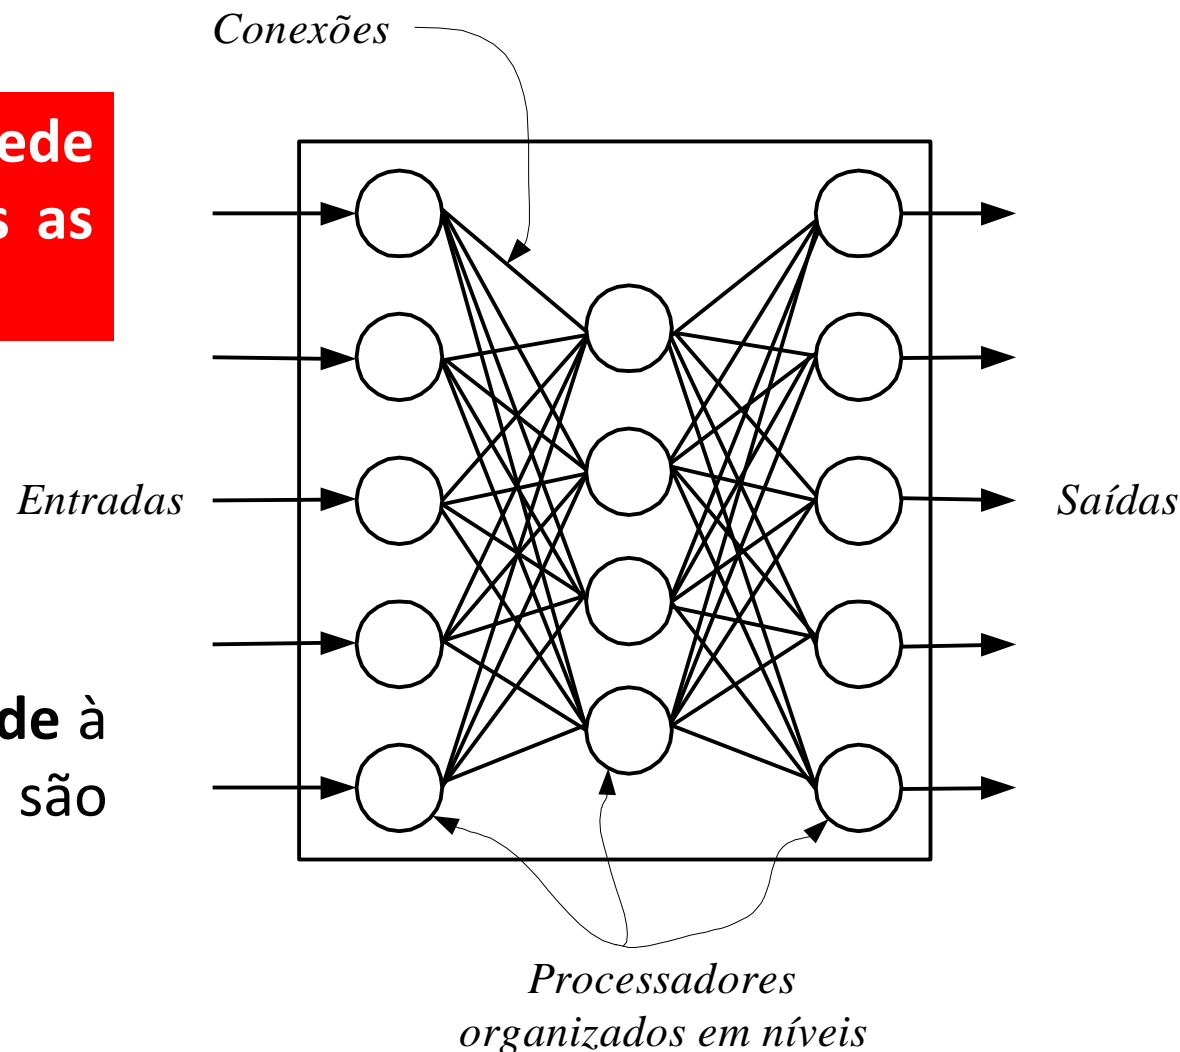
## Quais as suas aplicações nas Engenharias?

- Sistemas que detetam explosivos nas portas dos aeroportos.
- Reconhecimento automático de caracteres em sistemas de leitura.
- Sistemas de visão em robótica.
- Sistemas de reconhecimento de voz (e.g.: computadores e sistemas telefónicos).
- Sistemas de previsão ( e.g.: clima , investimentos financeiros, etc.)
- Reconhecimento de padrões.

## Arquitetura geral de uma Rede Neuronal


O poder computacional da rede advém das conexões entre as múltiplas unidades.

- Chama-se **Topologia da Rede** à forma como as unidades são ligadas.



## Inspiração Natural: Estrutura de um neurónio

Entradas



Os **neurónios** estão conectados por **sinapses**, que produzem uma **resposta** química a “uma” **entrada**.


Extraído de:

<https://en.wikipedia.org/wiki/Dendrite>

Acedido em 11-4-2020

## Inspiração Natural: Estrutura de um neurónio

Entradas



O tamanho da resposta varia de acordo com a soma das reações da sinapse.

Extraído de:

<https://en.wikipedia.org/wiki/Dendrite>

Acedido em 11-4-2020


Se esse valor ultrapassar um determinado valor o neurónio dispara.



Os primeiros modelos para representar neurónios foram desenvolvidos por McCulloch e Pitts.

As entradas e saídas são variáveis binárias!

$$x = (x_1, x_2, \dots, x_n)$$

$$x_n \in [0,1]$$








## Neurónio de Mculloch e Pitts


✓ Representação alternativa:



$$y = f(g(x)) = \begin{cases} 1 & \Leftarrow g(x) \geq \theta \\ 0 & \Leftarrow g(x) < \theta \end{cases}$$

$$g(x) = x_1 + x_2 + \dots + x_n$$


## Função AND



Porquê?

$x1$	$x2$	$g$	$y$
0	0		
1	0		
0	1		
1	1		


## Neurónio de Mculloch e Pitts



$$y = f(g(x)) = \begin{cases} 1 & \Leftarrow g(x) \geq \theta \\ 0 & \Leftarrow g(x) < \theta \end{cases}$$

$$g(x) = x_1 + x_2 + \dots + x_n$$


## Função OR



Porquê?

$x1$	$x2$	$g$	$y$
0	0		
1	0		
0	1		
1	1		


## Neurónio de Mculloch e Pitts



$$y = f(g(x)) = \begin{cases} 1 & \Leftarrow g(x) \geq \theta \\ 0 & \Leftarrow g(x) < \theta \end{cases}$$

$$g(x) = x_1 + x_2 + \dots + x_n$$


## Função OR



## Porquê?

$x_1$	$x_2$	$g$	$y$
0	0		
1	0		
0	1		
1	1		

## Neurónio de Mculloch e Pitts




$$y = f(g(x)) = \begin{cases} 1 & \Leftarrow g(x) \geq \theta \\ 0 & \Leftarrow g(x) < \theta \end{cases}$$

$$g(x) = x_1 + x_2 + \dots + x_n$$

## Função NOT


✓ Com Entrada Inibidora:



## Porquê?

$x_1$	$g$	$y$
0	0	1
1	-	0


## Neurónio de Mculloch e Pitts



$$y = f(g(x)) = \begin{cases} 1 & \Leftarrow g(x) \geq \theta \\ 0 & \Leftarrow g(x) < \theta \end{cases}$$

$$g(x) = x_1 + x_2 + \dots + x_n$$

✓ Que função lógica implementa o seguinte neurónio?



$x1$	$x2$	$g$	$y$
0	0		
1	0		
0	1		
1	1		

## Neurónio de McCulloch and Pitts

✓ Limitações:

- E se as entradas forem não Booleanas?
- É necessário de codificar o limite (*threshold*) para cada caso?
- E se as entradas tiverem relevâncias distintas?
- Pode classificar funções não linearmente separáveis ( e.g. XOR)?

**Necessitamos do Perceptrão proposto por Rosenblatt em 1958**


## Perceptrão de Rosenblatt (TLU)

✓ Entradas:

$$x = (x_1, x_2, \dots, x_n)$$

✓ Fatores de peso:

$$w = (w_1, w_2, \dots, w_n)$$




Esta unidade é frequentemente chamada de **Threshold Logic Unit (TLU)**.

$$g(x, w) = x \cdot w = x_1 w_1 + x_2 w_2 + \dots + x_n w_n$$

$$y = f(g(x, w)) = \begin{cases} 1 & \Leftarrow g(x, w) \geq \theta \\ 0 & \Leftarrow g(x, w) < \theta \end{cases}$$

Saída



Entrada

Limite  
Threshold


## Exemplo:

✓ Entradas:

$$x = (1, 1, 0)$$

✓ Fatores de peso:

$$w = (0.5, 1, 1.2)$$



$$g(x, w) = x \cdot w = x_1 w_1 + x_2 w_2 + x_3 w_3$$

$$g = 1(0.5) + 1(1) + 0(1.2) = 1.5$$

$$y = f(g(x, w)) = \begin{cases} 1 & \Leftarrow g(x, w) \geq 1 \\ 0 & \Leftarrow g(x, w) < 1 \end{cases}$$

✓ Como neste caso  $g=1.5 \geq 1$  temos que  $y=1$ .



A característica fundamental de qualquer rede neuronal é que é composta por muitas unidades interconectadas, em que cada uma executa uma soma ponderada das suas entradas.


➤ A unidade representada tem:

- **$n+1$  entradas,  $x_i$ , e uma única saída  $y$ .**
- Cada entrada (ou arco) tem associada **um peso,  $w_i$** , que é um número real.

➤ Em cada unidade é feita uma soma ponderada:


$$g(x, w) = \omega_0 x_0 + \omega_1 x_1 + \dots + \omega_n x_n = \sum_{i=0}^n \omega_i x_i$$

- Esta soma ponderada vai ser o **argumento de uma função,  $f$** , que vai determinar o valor da saída da unidade.




## Função Ativação

- ✓ Uma função de saída típica (Heaviside) produz um 1 na saída quando a entrada é maior ou igual a zero e 0 no caso contrário:



O Bias pode ser aplicado noutra entrada.

- ✓ Na soma ponderada os termos  $x_1$  a  $x_n$  são variáveis, mas o termo  $x_0$  tem um valor fixo igual a 1:


$$g(x, w) = \boxed{\omega_0 x_0} + \omega_1 x_1 + \dots + \omega_n x_n = \sum_{i=0}^n \omega_i x_i$$

**Termo de Offset ou Bias**


- ✓ Este termo de bias está relacionado com a deslocação do *threshold* ( $\theta$ ) para a esquerda ou direita.

- ✓ Um **objeto** pertence a uma certa classe se tem **propriedades** que são **similares** a outros objetos dessa classe.



- ✓ De uma forma geral efetua-se uma comparação do objeto a classificar com um modelo ideal (para a banana e para a pera) do **objeto tipo que define a categoria**.

- ✓ Nos casos em que não existe um modelo para comparar os objetos a classificar **as redes neurais são uma alternativa.**
- ✓ As características gerais de uma classe tem de ser inferidas de exemplos "vistos".




- ✓ Nos método de aprendizagem que vamos abordar com redes neuronais, os **dados utilizados no seu treino** incluem **a(s) entrada(s) e a saída(s) desejada(s)** ( chamadas de **alvo ou *target*** ) que são **conhecidas à priori**.
- ✓ Esta abordagem chama-se **Aprendizagem Supervisionada**.
- ✓ Como vamos ver melhor os dados têm de ser organizados em :
  - **conjunto de treino**
  - **conjunto de validação**
  - **conjunto de teste**.

A rede neuronal deve possuir **Capacidade de Generalização**, ou seja, ser capaz de fornecer a resposta correta para dados não utilizados no seu treino.

# Classificação de Padrões com uma Unidade Neuronal

- ✓ Considere-se a seguinte unidade neuronal artificial:



- ✓ Equação geral de uma reta:

$$y = mx + c$$

$$m = -\frac{w_1}{w_2}$$

$$c = \frac{\theta}{w_2}$$

## Classificação de Padrões com uma Unidade Neuronal

- ✓ Uma unidade neuronal pode classificar os padrões de uma função lógica


AND?

$x_1$	$x_2$	$y$
0	0	0
0	1	0
1	0	0
1	1	1

Classe 2: C1

Classe 1: C2

Espaço dos padrões



$$m = -\frac{w_1}{w_2} = -\frac{0.5}{0.5} = -1$$

$$c = \frac{\theta}{w_2} = \frac{1}{0.5} = 2$$

- ✓ Resultado da classificação:


$x_1$	$x_2$	$x.w$	$y$
0	0	0	0
0	1	0.5	0
1	0	0.5	0
1	1	1	1

## Classificação de Padrões com uma Unidade Neuronal


$x_1$	$x_2$	$y$
0	0	0
0	1	0
1	0	0
1	1	1

Classe 2: C1

Classe 1: C2



✓ Classificação binária.




- ✓ Espaço dos padrões bidimensional  $\Rightarrow$  discriminante é uma reta
- ✓ Espaço dos padrões  $n$ -bidimensional  $\Rightarrow$  discriminante é uma superfície com dimensões  $(n-1)$ : **Hiperplano**.



# Classificação de Padrões com uma Unidade Neuronal


- ✓ A figura seguinte mostra: uma unidade com duas entradas  $x_1$  e  $x_2$  capaz de executar a função **and** e a tabela com os cálculos



$x_0$	$x_1$	$x_2$	$g = w_0x_0 + w_1x_1 + w_3x_3$	$y$
1	0	0	<b><math>-1.5x_1 + 0x_1 + 1x_0 = -1.5</math></b>	0
1	0	1	<b><math>-1.5x_1 + 0x_1 + 1x_1 = -0.5</math></b>	0
1	1	0	<b><math>-1.5x_1 + 1x_1 + 0x_1 = -0.5</math></b>	0
1	1	1	<b><math>-1.5x_1 + 1x_1 + 1x_1 = +0.5</math></b>	1

# Classificação de Padrões com uma Unidade Neuronal


- ✓ A figura seguinte mostra: uma unidade com duas entradas  $x_1$  e  $x_2$  capaz de executar a função **or** e a tabela ( confirme os cálculos ).



$x_0$	$x_1$	$x_2$	g	y
1	0	0	<b>-0.5</b>	0
1	0	1	<b>+0.5</b>	1
1	1	0	<b>+0.5</b>	1
1	1	1	<b>+1.5</b>	1

# Classificação de Padrões com uma Unidade Neuronal

- ✓ A figura seguinte mostra uma unidade com uma entrada  $x_1$  capaz de executar a função de negação e a tabela.



$x_0$	$x_1$	$g$	$y$
1	0	+0.5	1
1	1	-0.5	0

A partir destas três funções (*and*, *or* e *not*) é possível implementar qualquer função lógica.

Isto significa que computadores convencionais *podiam* ser construídos usando estas unidades neuronais artificiais em vez dos usuais circuitos lógicos com transístores.

# Classificação de Padrões com uma Unidade Neuronal

- ✓ Considere-se o seguinte exemplo [1]:
- ✓ A que classe é que pertence a amostra ( $x_1=2.0$ ,  $x_2=4.5$ )?




<i>Amostra</i>	$x_1$	$x_2$	<i>Classificação</i>
1	2.0	3.5	A
2	3.0	1.5	B
3	4.5	1.5	B
4	1.5	2.0	B
5	3.0	4.5	A
6	2.0	5.0	A
7	4.0	3.0	B
8	3.0	3.0	B
9	3.0	5.5	A
10	4.0	4.5	A

[1] Johnson J. and Picton P, Concepts on Artificial Intelligence, Designing Intelligent Machines, Part II, Butterworth-Heinemann

## Classificação de Padrões com uma Unidade Neuronal

- ✓ A que classe é que pertence a amostra ( $x_1=2.0$ ,  $x_2=4.5$ )?



Amostra	$x_1$	$x_2$	Classificação
1	2.0	3.5	A
2	3.0	1.5	B
3	4.5	1.5	B
4	1.5	2.0	B
5	3.0	4.5	A
6	2.0	5.0	A
7	4.0	3.0	B
8	3.0	3.0	B
9	3.0	5.5	A
10	4.0	4.5	A


- ✓ Para determinar se um ponto pertence à classe A ou B só temos de determinar de que lado da reta está.

# Classificação de Padrões com uma Unidade Neuronal

Como se pode testar se um ponto está à esquerda ou à direita da linha?

$$y = mx + c$$

$$x_2 = mx_1 + c$$



$$x_1 = 0 \Rightarrow c = x_2 = 2$$

$$x_2 = 0 \Rightarrow 0 = -4m + 2$$

✓ Assim a equação da  $\therefore m = 0.5$  reta é:  $x_2 = 0.5x_1 + 2$


$$\text{ou: } x_2 - 0.5x_1 - 2 = 0$$

- ✓ Substituindo  $x_1$  e  $x_2$  nesta equação se o resultado for:
- $= 0$ , significa que o ponto está na reta;
  - $> 0$ , significa que o ponto pertence a A;
  - $< 0$ , significa que o ponto pertence a B.

# Classificação de Padrões com uma Unidade Neuronal

✓ Vamos confirmar que  $(x_1=2.0, x_2=4.5)$  pertence a A:  $x_2 - 0.5x_1 - 2 = 0$

$$x_2 - 0.5x_1 - 2.0 = 4.5 - 0.5(2.0) - 2.0 = 1.5$$

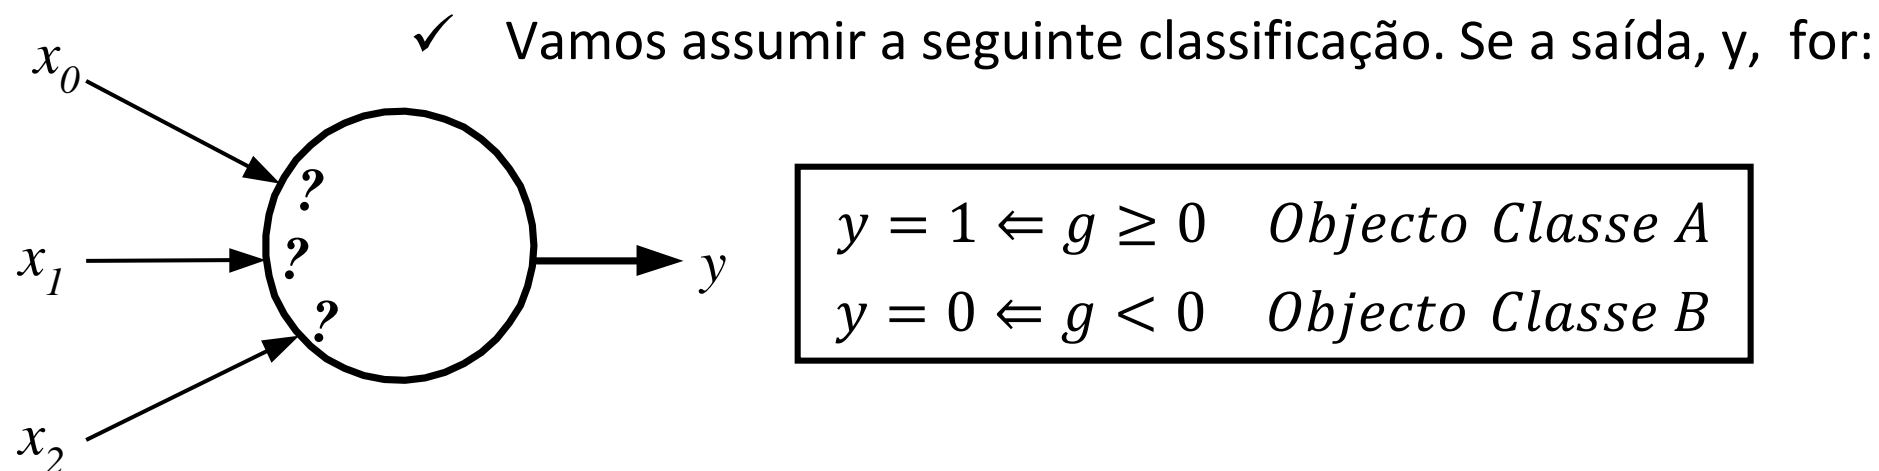


✓ como o resultado é  $> 0$ , significa que o ponto pertence à classe A;

Pode-se utilizar uma unidade neuronal para o mesmo fim?

# Classificação de Padrões com uma Unidade Neuronal

Unidade com duas entradas:



- ✓ A título de exercício vamos determinar **quais os pesos necessários** para obter a classificação destas duas classes com esta unidade neuronal.




# Classificação de Padrões com uma Unidade Neuronal

Quais são os pesos?

✓ A partir da soma:

$$g = \sum_{i=0}^2 \omega_i x_i = \omega_0 x_0 + \omega_1 x_1 + \omega_2 x_2$$



$$\begin{aligned} y = 1 &\Leftarrow \omega_0 x_0 + \omega_1 x_1 + \omega_2 x_2 \geq 0 && \text{Objecto ClasseA} \\ y = 0 &\Leftarrow \omega_0 x_0 + \omega_1 x_1 + \omega_2 x_2 < 0 && \text{Objecto ClasseB} \end{aligned}$$

➤ A linha divisora entre correspondente à divisão entre as duas classes é representada por:

$$w_0 x_0 + w_1 x_1 + w_2 x_2 = 0$$

$$w_2 x_2 = -w_1 x_1 - w_0 x_0 \Leftrightarrow x_2 = -\frac{w_1}{w_2} x_1 - \frac{w_0}{w_2} x_0$$

$$x_2 = m x_1 + c$$

$$m = -\frac{w_1}{w_2}$$

$$m = 0.5$$

$$c = -\frac{w_0}{w_2}$$

$$c = 2$$

# Classificação de Padrões com uma Unidade Neuronal

## Quais são os pesos?

➤ Já tínhamos concluído que neste caso:


$$m = 0.5$$

$$c = 2$$

$$m = -\frac{w_1}{w_2}$$

$$c = -\frac{w_0}{w_2}$$

$$w_2 = 1.0 \Rightarrow \begin{cases} w_0 = -2.0 \\ w_1 = -0.5 \end{cases}$$



✓ Vamos testar com  $(x_1=2.0, x_2=4.5)$  :


$$g = w_0x_0 + w_1x_1 + w_2x_2 = -2(1) + (-0.5)2 + 4.5(1) = 1.5$$

$$g = 1.5 > 0 \Rightarrow y = 1 \Rightarrow \textit{Categoria A}$$

# Classificação de Padrões com uma Unidade Neuronal

## Generalização

O ponto  $x_1=2.0$ ,  $x_2=4.5$  não estava no conjunto de amostras iniciais



Uma unidade com estes pesos consegue classificar amostras que não estavam no conjunto inicial. A esta capacidade de classificar exemplos não “vistos” antes chama-se generalização.

<i>Amostra</i>	$x_1$	$x_2$	<i>Classificação</i>
1	2.0	3.5	A
2	3.0	1.5	B
3	4.5	1.5	B
4	1.5	2.0	B
5	3.0	4.5	A
6	2.0	5.0	A
7	4.0	3.0	B
8	3.0	3.0	B
9	3.0	5.5	A
10	4.0	4.5	A

# Classificação de Padrões com uma Unidade Neuronal

Conclui-se que uma unidade é capaz de efetuar a classificação se os dados forem linearmente separáveis:

E para dados não separáveis linearmente?

- Como é que as unidades neuronais podem ser utilizadas para classificar dados não linearmente separáveis?
- Antes de abordar esta questão vamos ver **como se processa a aprendizagem num perceptrão.**

